Voice Guard
论文质量复现补充实验

本报告记录 2026 年 11 月 9 日的第二轮补充实验。本轮独立于已完成的课程实验，旧 WAV、分数和冻结验证不覆盖。

评估差异与同 WAV 重评

先前 1NEYRON1/mosnet 含 BatchNorm、频谱默认 Hann；MOSNet 作者公开的 CNN-BLSTM 不含 BatchNorm，使用对称 Hamming 窗，其 Keras 2.1.2 检查点循环门为 hard-sigmoid。这是不同的评估器，不能视为同一刻度。

本轮下载 lochenchou/MOSNet 固定提交 3ea20beaa3c1e886464fe0b1b9807fa62c732029，权重 SHA256 78b75e7d76ee6074ea7d57dcffa56d0c90be9d3d8dedc2217e25e259423cb756。新增移植与 TensorFlow 原 H5 在三种固定频谱上对照，最大逐帧误差 0.000001431，容差 0.0001。此核验不能证明该公开权重就是 Voice Guard 作者实际使用的检查点。

历史音频组	原始 MOSNet 平均预测
首批五句干净裁剪语音	3.962
首批五句原 VG	2.551
首批改进开发两句	4.408
首批改进验证三句	3.827
原冻结十句干净裁剪语音	3.940
原冻结十句原 VG	2.702
原冻结十句固定改进	3.958
原冻结十句完整干净上下文	3.827
原冻结十句完整保护上下文	3.857

分数另存 docs/evidence/2026-11-09-quality/original-mosnet-audit.json，旧观测保持原样。改进音频预测音质更接近论文，仍不能据此宣布总体防护达标。

论文表 2 白盒 VG 报告保护 MOS 4.07、WER 7.84%、联合防护 80.06%。Eq.10 对转换端使用身份改变、自然度不达标、内容不完整的“或”条件，旧项目仅计身份改变，本轮并列报告。

保留历史 Whisper/ASV、仅追加原始 MOSNet 后，原冻结十句改进的严格联合为 1/8，按 Eq.10 结构且仅筛干净身份为 4/8；完整上下文分别为 1/7、6/7。这是评估器与判据变化，不构成新增算法改善。 若要求干净转换通过 MOS/WER，三组分母均为 0，结果为 N/A。

干净转换自身存在较多 Whisper base 内容错误，不能归因于扰动。新一轮另外预先声明 small.en 和 Resemblyzer GE2E 独立复核，不逐音频选更有利的模型。

新算法与验证设计

vguard/recovery.py 是独立实验实现，不改变原 voice_guard_attack：

- 掩蔽谱投影之外加入全局 SNR 与峰值约束。

- 比较直接嵌入目标与解码后声纹反馈，使用两个固定内容源。

- 保留完整原音，仅在原裁剪区间加扰动，PCM16 导出后评分。

- ECAPA、GE2E、MOSNet、Whisper 不进入优化损失。反馈梯度经过 mel 解码器，未经过波形声码器。

三配置、500/1500 步、开发三句和验证十五句在实验前写入 recovery-protocol.json。只按开发结果选一个全局配置，不逐验证样本选版本。验证包含已见人物十个新句及未参与本轮攻击开发的五位人物各一句；人物仍在注册库，也可能被 VC 预训练见过。

每个验证句以两个内容源重新合成干净/保护后的 VC，并列报告身份门槛、Eq.10 结构门槛及完整干净控制门槛。内容源重复不是独立人物。

计划计算上限为开发、验证各一小时，超时不会自动停止 ECS 计费。开发、冻结验证及独立补评均已完整结束，结果见下文。

冻结验证最终结果

开发三句、三配置、两个步数共 18 条已完成。按预先声明规则选取全局反馈目标、20 dB SNR 预算、1500 步。选择后才开始十五句验证，未因验证结果更换配置。

所选配置开发严格联合 1/3；开发保护质量 3/3。开发结果用于选择，不能替代独立验证。

验证完整完成：15 个保护原音、10 位说话人、两个内容源，共 30 对干净/保护转换。音质与逐句 WER 对保护 WAV 去重，防护率逐内容源列出；两个内容源是相关重复。

保护原音指标	本轮结果	论文表 2
原始 MOSNet 预测均值	4.063	4.07
Whisper base 逐句 WER 均值	4.61%	7.84%
small.en 逐句 WER 均值	1.33%	非同评估器
ECAPA 身份保留	15/15	非同评估器
GE2E 身份保留	15/15	非同检查点
实际完整波形平均 SNR	21.62 dB	不直接对比

干净原音原始 MOSNet 均值 3.994，Whisper base 逐句 WER 5.35%。这些是自动模型预测，尚无真人 MOS 问卷结果。

防护判据与干净控制

严格联合要求保护原音身份、MOS、内容都保留，同时转换身份改变。Eq.10 结构允许转换身份改变、MOS<3、WER>10% 任一成立。完整干净控制额外要求零扰动转换本身通过身份、MOS 和 WER；分母为零时写 N/A。

评估组合 / 内容源	严格联合	Eq.10 结构	完整干净控制
ECAPA_Whisper_base / 合并相关转换对	8/21 (38.1%)	16/21 (76.2%)	4/7 (57.1%)
ECAPA_Whisper_base / p226_002	3/10 (30.0%)	8/10 (80.0%)	0/1 (0.0%)
ECAPA_Whisper_base / p227_002	5/11 (45.5%)	8/11 (72.7%)	4/6 (66.7%)
GE2E_Whisper_small_en / 合并相关转换对	11/27 (40.7%)	16/27 (59.3%)	5/12 (41.7%)
GE2E_Whisper_small_en / p226_002	5/14 (35.7%)	8/14 (57.1%)	2/5 (40.0%)
GE2E_Whisper_small_en / p227_002	6/13 (46.2%)	8/13 (61.5%)	3/7 (42.9%)

分母仅纳入相应干净控制合格的转换；分子始终同时要求保护原音身份及质量合格。不能把既有的转换内容错误视为扰动的因果贡献。论文 80.06% 是不同实验规模、语音转换和评估设置下的值，本表不构成数值等价复现。

两组说话人的结果

评估组合 / 组别	句数	严格联合（相关转换对）	Eq.10（相关转换对）
ECAPA_Whisper_base / p225-p229 新句	10	6/15 (40.0%)	12/15 (80.0%)
ECAPA_Whisper_base / p230-p234 未用于攻击开发	5	2/6 (33.3%)	4/6 (66.7%)
GE2E_Whisper_small_en / p225-p229 新句	10	8/19 (42.1%)	12/19 (63.2%)
GE2E_Whisper_small_en / p230-p234 未用于攻击开发	5	3/8 (37.5%)	4/8 (50.0%)

后五位说话人仍在注册库中，也可能出现在转换器预训练数据中，因此这里只能声称未用于本轮攻击开发，不能声称完全未见说话人泛化。

失败样例与约束残差

唯一未通过保护原音质量门槛的句子是 p227_053。参考为 "Four other charges were dropped."；base 对干净和保护音频均输出 "Foot of the charges were dropped."，WER 均为 60%。small.en 对干净音频输出正确的 Four，对保护音频输出数字 4，因此按冻结文本规则计 WER 20%。这说明机器转录门槛含识别器及文本形式因素，不能完全替代真人可懂度；本轮未据此改变归一化或重新计分。原始观测全部保留。

PCM16 导出后，平均时频单元掩蔽超额比例为 0.528%，平均正超额为 0.01357 dB。投影有残差，不能宣称每个时频点严格满足掩蔽阈值。全局 SNR 与峰值预算另行约束。

结论与未达到的目标

本轮保护 MOS 预测 4.063，但严格防护与完整干净控制下的证据仍不足以支持论文级总体复现。保护原音高音质和内容保留，是必要条件，不是联合防护成功的充分条件。

干净 AdaIN-VC 输出本身常有内容识别错误，已分别保留 base 和 small.en 原始转录。不得加入参考文本提示、挑选逐句更有利的评估器或更换验证配置来提高分数。另一次研究若要修正转换器或引入神经声码器，应使用新协议、新开发集及新验证集，并与本轮结果分开。

本轮没有同十五句的原 VG 对照，因此不能用旧五句/十句的不同数据均值宣称新算法因果改善。论文规模、多转换器泛化、真人听测、原作者未公开实现和精确评估检查点也未补齐。所有失败均留存。

复跑、资源与证据

新增推理依赖见 deploy/quality-recovery-requirements.txt；在原部署环境中安装。tools/download_models.py 支持 mosnet-original（固定提交、校验 SHA）。tools/download_quality_asr.py 下载固定 small.en 权重；GE2E 来自固定 Resemblyzer 0.1.4，注册库使用二十人各前三十句，资源与六百输入哈希见 ge2e-resources.json。旧模型压缩包不包含这些新增资源；本轮另提供 VoiceGuard-quality-evaluator-resources.zip（约 515 MB），含恢复说明、原始 MOSNet、small.en、GE2E 权重及注册库，仍需与旧完整模型包配合。尚无真实云盘分享链接。

tools/verify_original_mosnet.py 支持 PyTorch、隔离 TensorFlow 和 compare 三种模式；正常推理不依赖 TensorFlow。冻结协议校验源码、资产和选择文件。原开发/验证 runner、补评 runner 和协议不应修改后冒充原实验。

离线分析：python tools/analyze_quality_recovery.py --root <解压目录>/outputs/paper_quality/2026-11-09-recovery。分析工具拒绝未完成、缺失、重复或错误配置的验证结果。原始表格、转录、全部 WAV、执行源码快照和注册库保存在独立 final-recovery-evidence.tar.gz；旧 final-complete-evidence.tar.gz 保留。

本轮补充报告以本文件与 recovery-analysis.json 为依据。原课程报告 PDF 和九分钟 PPT 是上一轮交付，不含此轮新增结果，应与本补充报告一起阅读。ECS 未自动关机，空闲时仍可能计费。

证据索引：recovery-protocol.json、recovery-selection.json、supplemental-protocol.json、mosnet-parity.json、original-mosnet-audit.json、archived-paper-criteria.json、recovery-analysis.json、recovery-archive-verification.json。全部位于 docs/evidence/2026-11-09-quality/。